

UNIVERSIDADE ESTADUAL DE CAMPINAS
INSTITUTO DE COMPUTAÇÃO

MC859 - PROJETO EM TEORIA DA COMPUTAÇÃO

Análise de redes de similaridade genética entre doenças: identificação de padrões e comunidades a partir do DisGeNET

Aluno

Daniel Henriques Pamplona - RA: 260401

Professor

Prof. Ruben Interian Kovaliova

Campinas, 10 de fevereiro de 2026

Conteúdo

1	Introdução	2
2	Coleta e processamento de dados	2
2.1	Escolha dos pesos das arestas	2
2.2	Filtragem	3
2.2.1	Filtragem por <i>threshold</i>	3
2.2.2	Filtragem por PMFG	3
2.2.3	Filtragem por TMFG	4
3	Análises do grafo final	5
3.1	Estrutura e tamanho do grafo	5
3.2	Conectividade	5
3.3	Distribuição de graus	5
3.4	Medidas de Centralidade	6
3.4.1	Grau	6
3.4.2	<i>Betweenness</i>	7
3.4.3	<i>Closeness</i>	8
3.4.4	<i>Eigenvector</i>	8
3.5	Assortatividade	9
3.6	Clusterização	9
3.7	Detecção de Comunidades	11
3.8	<i>Link Prediction</i>	11
3.9	<i>Triadic Closure</i>	14
4	Visualização da rede	14
5	Conclusão	16
	Referências	16

1 Introdução

Este projeto tem como objetivo principal a modelagem de relações complexas entre doenças a partir de grandes bases de dados biomédicas, representando-as como grafos para a descoberta de padrões não triviais. Especificamente, o trabalho foca na construção e análise de uma rede de similaridade genética entre doenças, utilizando para isso o vasto conjunto de dados de associações gene-doença disponibilizados pela plataforma DisGeNET. O propósito é identificar *clusters* de doenças que compartilham mecanismos genéticos, quantificar a força dessas relações, investigar outras informações como a identificação e interpretação de *triadic closures*, *link prediction* e visualizações que evidenciem quais patologias estão mais intimamente relacionadas. Todos os códigos, dados processados e resultados obtidos neste projeto estão disponíveis no repositório: https://github.com/yobinad1/projeto_mc859.

2 Coleta e processamento de dados

Para a coleta de dados, foi utilizado o repositório `dhimmel/disgenet`^[1], disponível no GitHub, que oferece arquivos já processados contendo associações extraídas da base DisGeNET. A escolha por esse repositório foi justamente dispensar a necessidade de implementar consultas diretas à API oficial, já que o repositório contém os dados estruturados e prontos para a análise. O arquivo principal utilizado para a análise foi o `all_gene_disease_associations.txt.gz`, contido na pasta de *download* do repositório.

Antes da criação do grafo, foi feito um pré-processamento dos dados em um ambiente *python* utilizando a biblioteca *pandas*. Esta etapa incluiu a seleção das colunas relevantes para a análise, bem como a remoção de doenças que não tinham identificação e a padronização de doenças que apareciam com múltiplos identificadores. As 3 *features* desse *dataset* utilizadas são: *geneId*, que identifica o gene; *diseaseId*, que identifica a doença; *score*, que mede a confiabilidade da relação entre aquela doença e aquele gene analisado.

Depois do processamento do *dataset*, prosseguimos com a criação do grafo. Primeiramente, criamos um grafo bipartido doença-gene, onde o peso de cada aresta é exatamente a confiabilidade da relação entre aquela doença e aquele gene, ou seja, o *score*. Após isso, projetamos o grafo bipartido doença-gene para o grafo doença-doença, onde será feita a análise da relação entre as doenças.

2.1 Escolha dos pesos das arestas

A ideia inicial para definir o peso da aresta entre duas doenças foi utilizar a soma das médias dos *scores* que cada doença possui com os genes que elas compartilham. Por exemplo, considere duas doenças D_1 e D_2 que têm em comum os genes G_1 , G_2 e G_3 . Nesse caso, o peso da aresta seria dado pela média dos *scores* de D_1 com esses genes somada à média dos *scores* de D_2 com os mesmos genes. Entretanto, essa abordagem apresenta um problema: relações fortes podem ser mascaradas por valores baixos de *score*, fazendo com que o peso final da aresta seja menor do que o esperado. Isso não é desejável, já que pode enfraquecer artificialmente a importância de conexões relevantes. Por esse motivo, adotamos uma estratégia alternativa: definir o peso da aresta como o menor valor de *score* entre as duas doenças e os genes compartilhados. No exemplo anterior, entre D_1 , D_2 e os genes G_1 , G_2 e G_3 , o peso corresponderia ao menor *score* encontrado. Esse valor funciona como um *lower bound*, representando a confiança mínima existente na relação entre as doenças.

O grafo doença-doença resultante desse processo de projeção, no entanto, é extremamente denso, contendo 14.246 vértices e 7.447.352 arestas. Essa alta densidade, além de impor um alto custo compu-

tacional para a aplicação de algoritmos de análise mais complexos, dificulta a extração de padrões significativos. A estrutura da rede fica ofuscada por uma grande quantidade de “ruído”, ou seja, arestas que representam associações genéticas fracas ou indiretas que não são biologicamente relevantes. Diante disso, torna-se essencial a aplicação de um procedimento de filtragem para extrair uma sub-rede que retenha apenas as conexões mais importantes e represente a estrutura fundamental das relações genéticas entre as doenças, viabilizando assim análises mais aprofundadas e computacionalmente tratáveis.

2.2 Filtragem

2.2.1 Filtragem por *threshold*

Inicialmente, realizamos uma análise exploratória utilizando diferentes valores de limiar para os pesos das arestas, com o objetivo de reduzir tanto a quantidade de nós quanto de arestas do grafo. Para isso, foram testados valores de *threshold* na faixa de 0 até 0.25 com passo de 0.01 e, para visualização, foram plotados gráficos que mostram como a quantidade de nós e arestas variam com o valor de *threshold*:




Figura 1: Quantidade de nós e de arestas por *threshold*

Como ilustrado na Figura 1, a topologia do grafo, em termos de número de nós e arestas, altera-se de forma acentuada em um ponto crítico: quando o *threshold* varia de 0.21 para 0.22. A partir deste ponto, o grafo assume uma dimensão mais tratável para análise, demandando consideravelmente menos recursos computacionais do que a rede original densa. Assim, se quiséssemos continuar com essa estratégia, o intervalo de *threshold* entre 0.21 e 0.22 pareceria o mais adequado para filtrar o grafo.

O grande problema dessa abordagem, no entanto, é que nosso objetivo não é apenas reduzir a densidade da rede, mas preservar informações estruturais importantes, como a existência de comunidades. Ao aplicar um corte brusco via *threshold*, podemos acabar eliminando justamente comunidades menores, mas relevantes, que se conectam por arestas de baixo peso. Em outras palavras, essa filtragem compromete a integridade das informações que buscamos extrair, tornando-se inadequada para a análise pretendida.

2.2.2 Filtragem por PMFG

O algoritmo PMFG^[2] (*Planar Maximally Filtered Graph*) foi considerado como alternativa ao corte por limiar, pois reduz a complexidade da rede preservando sua estrutura essencial. Ele constrói um subgrafo planar maximamente filtrado, mantendo informações críticas para análises como detecção de comunidades e identificação de nós centrais, funcionando como um filtro inteligente que conserva a “espinha dorsal” do grafo.

No entanto, a principal limitação do PMFG está no alto custo computacional, devido à necessidade

de verificar a planaridade do grafo a cada inserção de aresta — uma operação teoricamente linear, mas impraticável em redes grandes e densas. Testamos uma abordagem local, restringindo a verificação de planaridade a subgrafos induzidos pelos extremos da aresta candidata e seus vizinhos, buscando subdivisões de $K_{3,3}$ ou K_5 (Teorema de Kuratowski^[3]). Embora mais rápida, essa estratégia pode aceitar arestas que, globalmente, tornam o grafo não-planar, pois não garante a planaridade total. Dessa forma, apesar de suas vantagens conceituais, o PMFG mostrou-se inviável para o nosso conjunto de dados devido ao custo computacional elevado.

2.2.3 Filtragem por TMFG

O algoritmo TMFG^[4] (*Triangulated Maximally Filtered Graph*) surge como uma alternativa eficiente ao PMFG para a construção de subgrafos filtrados e planários. Enquanto o PMFG depende de verificações repetidas de planaridade a cada inserção de aresta, o TMFG foi projetado de forma construtiva, o que elimina a necessidade dessas verificações custosas e permite uma execução muito mais escalável em redes grandes.

A ideia central do TMFG é construir o grafo incrementalmente a partir de uma estrutura base formada por um tetraedro (um grafo completo com quatro vértices, K_4). Em seguida, novos vértices são adicionados ao grafo, sempre conectando-se a três vértices já presentes que formam uma face triangular. Esse processo garante que o grafo resultante seja planário e maximamente triangulado (ou seja, todas as faces são triângulos), sem a necessidade de checar explicitamente a planaridade. A escolha de onde inserir cada novo vértice é guiada pelos pesos das arestas: o algoritmo prioriza as conexões que maximizam a soma dos pesos preservados, de modo que os vínculos mais fortes do grafo original são mantidos na filtragem. Esse mecanismo faz com que o TMFG não apenas reduza a complexidade da rede, mas também preserve as informações estruturais mais relevantes.

O TMFG possui complexidade computacional quase linear no número de vértices, tornando-o adequado para redes densas e de grande porte. Além disso, como o processo construtivo favorece a formação de triângulos, ele enfatiza a estrutura de *clustering* da rede — característica essencial para análises de comunidades. Dessa forma, grupos de doenças fortemente interligados geneticamente continuam representados na rede filtrada, enquanto arestas fracas são naturalmente descartadas.

Algorithm 1: Construção do TMFG

Input: Matriz de pesos W de um grafo completo $G = (V, E)$
Output: Subgrafo planar triangulado $G' = (V, E')$
 Calcule o grau ponderado de cada vértice $v \in V$;
 Selecione os quatro vértices com maior grau e forme um tetraedro inicial T ;
 Inicialize E' com todas as arestas de T ;
 Inicialize a lista de faces triangulares F do tetraedro T ;
foreach vértice $u \in V \setminus T$ **do**
 foreach face triangular $f \in F$ **do**
 Compute $soma(u, f) = \sum_{x \in f} W[u, x]$;
 end
 Selecione a face f^* que maximiza $soma(u, f)$;
 Conecte u a todos os vértices de f^* e adicione essas arestas em E' ;
 Atualize F : remova f^* e adicione as três novas faces (u, f_i^*, f_j^*) ;
end
return $G' = (V, E')$;

Em resumo, o TMFG resolve a limitação prática do PMFG: mantém um grafo planar maximamente filtrado, mas com um custo computacional muito menor e com melhor preservação da organização modular da rede. Por isso, o TMFG se mostra a abordagem mais adequada para o presente projeto, equilibrando eficiência computacional e manutenção das informações relevantes para a análise de comunidades na rede de doenças e genes.

3 Análises do grafo final

Uma vez obtido o grafo filtrado, podemos dar início à caracterização de suas propriedades estruturais. A primeira etapa consiste em avaliar aspectos fundamentais como número de vértices, arestas, componentes conexas e a distribuição de graus.

3.1 Estrutura e tamanho do grafo

A primeira análise quantifica o tamanho e a densidade da rede. O grafo final é composto por:

- 14.246 vértices, onde cada vértice representa uma doença única.
- 36.409 arestas, representando as conexões de similaridade genética mais fortes.
- Um grau médio de 5.11.

A rede original, projetada a partir do grafo bipartido, era extremamente densa (com mais de 7 milhões de arestas). O algoritmo TMFG reduziu a rede a uma estrutura esparsa, onde cada doença está conectada, em média, a apenas 5 outras doenças. Essa redução torna a rede mais adequada para a identificação de padrões e comunidades, preservando as conexões mais relevantes.

3.2 Conectividade

A análise de conectividade do grafo revelou a existência de 4 componentes conexas. Isso indica que a maior parte das doenças está interligada em uma grande componente principal, enquanto alguns pequenos grupos de doenças permanecem isolados do restante da rede. Esses subconjuntos desconexos sugerem a presença de nichos genéticos específicos ou de doenças que não compartilham similaridade genética suficiente com as demais. Ainda assim, a existência de uma componente principal dominante reforça a coesão global da rede e sua utilidade para a análise de padrões e comunidades.

3.3 Distribuição de graus

Para entender a distribuição da conectividade na rede, foram geradas três visualizações dos graus: a primeira em escala linear, que não traz muitas informações relevantes devido à forte concentração de nós de baixo grau (Figura 2); a segunda em escala logarítmica apenas no eixo Y, que permite visualizar melhor a cauda da distribuição e identificar a existência de *hubs* (Figura 3); e a terceira em escala log-log, que é a mais adequada para investigar se a rede segue um comportamento do tipo lei de potência, característico de muitas redes complexas (Figura 4).




Figura 2: Distribuição de graus da rede




Figura 3: Distribuição de graus da rede na escala logarítmica




Figura 4: Distribuição de graus da rede em escala loglog

O gráfico demonstra claramente uma distribuição de grau do tipo “cauda longa” (*long-tail*), altamente assimétrica. A interpretação dessa estrutura é dupla:

1. A grande maioria das doenças possui um grau baixo, próximo ao grau médio de 5.11. Isso significa que a maior parte das patologias compartilha fortes similaridades genéticas com apenas um número restrito de outras doenças, comportando-se como nós “especialistas” na rede.
2. Um número muito pequeno de doenças possui um grau extremamente alto. Estes são os *hubs* da rede. Essas doenças-*hub* são de grande interesse biológico, pois atuam como pontos centrais que conectam muitas outras patologias distintas. Elas podem estar associadas a genes com múltiplas funções ou a vias biológicas fundamentais que, quando desreguladas, dão origem a uma vasta gama de condições clínicas.

Essa topologia é a marca registrada de redes do tipo livre de escala (*scale-free*), um padrão recorrente em sistemas complexos, incluindo redes biológicas, e indica que a rede não é aleatória, mas sim organizada em torno de alguns poucos elementos de alta importância.

3.4 Medidas de Centralidade

3.4.1 Grau

A análise da centralidade de grau destaca as doenças que mais compartilham genes com outras condições. Como mostra a Figura 5, “*Diabetes Mellitus, Experimental*” aparece como o nó mais conectado, indicando que está associada a um grande número de outras doenças. Isso sugere que os genes

relacionados ao diabetes têm participação em diversos processos biológicos, o que ajuda a explicar por que essa condição costuma estar ligada a várias outras complicações de saúde.

Entre as demais doenças mais conectadas, como “*Carcinoma*”, “*Hypertension*” e “*Craniofacial Abnormalities*”, também se observam altos níveis de associação com outras patologias. Esses resultados refletem a presença de genes compartilhados e a tendência de certas doenças atuarem como pontos centrais em redes biológicas mais amplas, influenciando ou sendo influenciadas por diferentes condições.




Figura 5: Dez maiores centralidades de grau na rede

3.4.2 Betweenness

A centralidade de *betweenness* destaca as doenças que funcionam como pontes entre diferentes partes da rede. Como mostra a Figura 6, “*Diabetes Mellitus, Experimental*” apresenta o maior valor nessa métrica, indicando que ela conecta grupos de doenças que, de outra forma, estariam mais isolados. Isso sugere que os genes associados ao diabetes podem ter papel importante na ligação entre diferentes conjuntos de condições.

Outras doenças com alta *betweenness*, como “*Craniofacial Abnormalities*”, “*Body Weight*”, “*Disease Models, Animal*” e “*Hypertension*”, também atuam como pontos de intermediação. Essas conexões indicam que certas doenças ajudam a integrar a rede como um todo, permitindo que informações genéticas circulem entre diferentes grupos e revelando possíveis relações indiretas entre condições distintas.




Figura 6: Dez maiores centralidades de *betweenness* na rede

3.4.3 Closeness

A centralidade de *closeness* indica quão rapidamente uma doença pode se conectar ou ser alcançada por outras dentro da rede. Valores altos sugerem que a condição está próxima, em termos de conexões genéticas, de grande parte das demais doenças. Como mostra a Figura 7, “*Diabetes Mellitus, Experimental*” apresenta a maior *closeness*, o que significa que está, em média, a poucas etapas das outras doenças. Isso reforça sua posição central e sua influência potencial sobre o restante da rede.

Entre as demais doenças com alta *closeness*, como “*Craniofacial Abnormalities*”, “*Liver Failure, Acute*” e “*Hypertension*”, observa-se um padrão semelhante: todas ocupam posições que facilitam a propagação de efeitos genéticos e o compartilhamento de informações entre diferentes regiões da rede.




Figura 7: Dez maiores centralidades de *closeness* na rede

3.4.4 Eigenvector

A centralidade de *eigenvector* identifica doenças que não apenas têm muitas conexões, mas que também estão ligadas a outras doenças igualmente bem conectadas. Dessa forma, ela destaca condições que fazem parte dos grupos mais influentes da rede. Como mostra a Figura 8, “*Diabetes Mellitus, Experimental*” apresenta o maior valor dessa métrica, indicando que está associada a um conjunto de doenças altamente conectadas entre si. Isso reforça sua presença em uma região central e influente da rede.

Outras doenças com alta centralidade de *eigenvector*, como “*Carcinoma*”, “*Prostatic Neoplasms*” e “*Hypertension*”, também participam desse núcleo interligado, sugerindo que estão inseridas em um contexto de forte correlação genética e influência mútua dentro da estrutura geral da rede.




Figura 8: Dez maiores centralidades de *eigenvector* na rede

A análise combinada das diferentes métricas de centralidade revela um padrão claro: "*Diabetes Mellitus, Experimental*" se destaca de maneira consistente, ocupando posições de liderança em todas as medidas (grau, *betweenness*, *closeness* e *eigenvector*). Este resultado indica que a doença não é apenas altamente conectada localmente, mas também desempenha papel estrutural crucial como ponte entre comunidades, está centralmente posicionada na rede e interage com outros nós influentes. Tal perfil sugere que ela pode ter um impacto biológico sistêmico significativo, refletindo tanto sua complexidade genética quanto seu potencial para influenciar múltiplas condições clínicas. Além disso, a convergência das métricas corrobora a existência de uma organização não aleatória da rede, possivelmente de tipo livre de escala, em que poucos nós estratégicos controlam a conectividade global.

3.5 Assortatividade

No grafo analisado, o coeficiente de assortatividade por grau obtido foi negativo, de valor -0.0647, indicando uma rede levemente desassortativa. Esse resultado é corroborado pela Figura 9, que mostra a relação entre o grau de cada nó e o grau médio de seus vizinhos: observa-se que, à medida que o grau do nó aumenta, o grau médio dos vizinhos tende a diminuir. Ou seja, os *hubs* da rede (doenças altamente conectadas) se ligam preferencialmente a doenças menos conectadas, e não a outros *hubs*.

Esse padrão é típico de redes biológicas e de sistemas complexos, como redes de doenças e proteínas, e está associado a uma maior robustez estrutural: *hubs* centralizam a conectividade e mantêm a coesão global, mas a ausência de conexões preferenciais entre eles pode tornar a rede mais vulnerável à remoção desses nós centrais. Em termos biológicos, isso sugere que doenças centrais atuam como pontos de integração, conectando múltiplas patologias periféricas e facilitando a propagação de informações genéticas ou mecanismos compartilhados ao longo da rede.




Figura 9: Relação entre o grau do nó e o grau médio de seus vizinhos na rede

3.6 Clusterização

O coeficiente de clusterização é uma métrica que quantifica a tendência de formação de grupos fechados (triângulos) na rede, ou seja, a probabilidade de que dois vizinhos de um mesmo nó também estejam conectados entre si. Valores elevados indicam a presença de comunidades densas e bem definidas, enquanto valores próximos de zero sugerem uma estrutura mais aleatória e dispersa.

No grafo analisado, o coeficiente de clusterização médio foi de 0.7272, valor consideravelmente superior ao observado em uma rede aleatória de mesmo porte (coeficiente médio de 0.0004). Esse resultado evidencia que a rede de doenças apresenta uma forte modularidade, com doenças tendendo a se agrupar

em comunidades coesas, característica típica de sistemas biológicos complexos.

A Tabela 1 apresenta os dez nós com maior e menor coeficiente de clusterização na rede. Observa-se que os nós com clusterização máxima (1.000) correspondem a doenças inseridas em pequenos grupos totalmente conectados. Já os nós com clusterização mínima (0.000) correspondem a vértices cujos vizinhos não estão conectados entre si, o que pode ocorrer tanto em *hubs* centrais — que integram diferentes comunidades — quanto em nós periféricos. Esses vértices são importantes para a conectividade global, mas não participam de agrupamentos fechados.

Tabela 1: Top 10 nós com maior e menor coeficiente de clusterização

Maior clusterização		Menor clusterização	
1.000	<i>Learning disabilities</i>	<i>Gait Ataxia</i>	0.000
1.000	<i>Dysmorphic features</i>	<i>FRAXE</i>	0.000
1.000	<i>Moderate mental retardation (I.Q. 35-49)</i>	<i>Periventricular Heterotopia</i>	0.000
1.000	<i>Lubs syndrome</i>	<i>Opitz GBBB Syndrome, X-Linked</i>	0.000
1.000	<i>Cerebral cortex myoclonus</i>	<i>Congenital absence of adrenal gland</i>	0.000
1.000	<i>Sustained ventricular tachycardia</i>	<i>Myofibrillar Myopathy</i>	0.000
1.000	<i>Induced ventricular tachycardia</i>	<i>Hepatic Fibrosis, Congenital</i>	0.000
1.000	<i>Gastrostomy</i>	<i>Chediak-Higashi Syndrome</i>	0.000
1.000	<i>Behavioral syndrome associated ...</i>	<i>Legius syndrome</i>	0.000
1.000	<i>Rett Syndrome, Preserved Speech Variant</i>	<i>Amaurosis</i>	0.000

A Figura 10a mostra a distribuição dos coeficientes de clusterização individuais, revelando que a maioria dos nós apresenta valores elevados (com um pico acentuado em 1), mas também existe uma fração significativa de vértices com clusterização igual a zero. Isso indica que muitos nós estão inseridos em grupos totalmente conectados, enquanto outros não formam triângulos com seus vizinhos. A relação entre grau e clusterização, ilustrada na Figura 10b, evidencia uma tendência inversa: nós com alto grau (os *hubs*) apresentam coeficiente de clusterização baixo ou nulo, enquanto nós de grau baixo ou intermediário tendem a formar grupos mais fechados. Esse padrão é típico de redes do tipo livre de escala, em que os *hubs* atuam como pontes entre diferentes comunidades, mas não participam de cliques densos.

A análise dos extremos reforça essa interpretação: doenças como “*Learning disabilities*”, “*Dysmorphic features*” e “*Moderate mental retardation (I.Q. 35–49)*” apresentam clusterização igual a 1, formando pequenos grupos totalmente conectados. Esse comportamento reflete módulos coesos de doenças com forte semelhança fenotípica e possivelmente mecanismos genéticos ou fisiopatológicos compartilhados.

Por outro lado, doenças como “*Gait Ataxia*” e “*FRAXE*” exibem clusterização igual a zero, indicando que, embora se conectem a múltiplas outras doenças, seus vizinhos não mantêm conexões entre si. Esse padrão pode refletir condições com relações muito específicas ou únicas, que não pertencem a um único grupo temático, ou ainda doenças raras que funcionam como pontes entre diferentes módulos, como entre grupos metabólicos, neurológicos ou genéticos. Esses nós de baixa clusterização tendem a ocupar posições periféricas ou intermodulares, contribuindo para a conectividade global da rede sem formar agrupamentos locais densos.

De forma geral, os resultados sugerem que a rede de doenças apresenta uma estrutura altamente modular, composta por comunidades densas interligadas por um número reduzido de nós de baixa clusterização. Tal organização reflete tanto a robustez quanto a especialização funcional observadas em

sistemas biológicos complexos.




Figura 10: Análise da clusterização da rede.

3.7 Detecção de Comunidades

A detecção de comunidades é uma etapa fundamental na análise de redes complexas, pois permite identificar grupos de nós (doenças) que estão mais densamente conectados entre si do que com o restante da rede. Esses agrupamentos podem revelar módulos funcionais, categorias clínicas ou conjuntos de doenças que compartilham mecanismos genéticos comuns.

Para tanto, foi utilizado o algoritmo de modularidade gulosa (*greedy modularity*), uma abordagem eficiente para grandes redes que busca maximizar a modularidade — métrica que quantifica a qualidade da divisão da rede em comunidades. O algoritmo identificou 46 comunidades na rede de doenças, com tamanhos bastante variados: as maiores comunidades possuem mais de 1.000 doenças, enquanto as menores reúnem menos de 5 vértices. Abaixo, na Tabela 2, encontram-se os valores de cada uma das 46 comunidades em ordem decrescente de tamanho.

Tabela 2: Tamanho das 46 comunidades detectadas pelo algoritmo de modularidade gulosa

1453	1319	1243	1177	1162	1143	1092	874
640	528	456	357	326	308	224	192
166	155	154	147	126	115	112	110
94	85	78	66	58	52	38	34
26	22	18	15	15	13	13	11
10	8	5	2	2	2		

A distribuição dos tamanhos das comunidades sugere uma estrutura modular heterogênea, típica de redes biológicas, em que poucos módulos concentram grande parte dos nós, enquanto outros representam grupos mais específicos ou raros. As maiores comunidades podem corresponder a grupos de doenças com forte compartilhamento genético, enquanto as menores podem indicar nichos biológicos ou clínicos mais restritos. A identificação dessas comunidades é relevante tanto para a compreensão da organização global da rede quanto para a priorização de grupos de doenças em estudos posteriores, como análise de comorbidades, busca de biomarcadores ou desenvolvimento de terapias direcionadas.

3.8 Link Prediction

A predição de links (*link prediction*) é uma tarefa fundamental em análise de redes, especialmente em contextos biológicos, pois permite inferir possíveis conexões ausentes ou prever relações ainda não

observadas entre doenças. Avaliamos, então, quatro métodos clássicos de predição de *links*: *Adamic-Adar*, *Resource Allocation*, *Jaccard* e *Preferential Attachment*.

Cada um desses algoritmos reflete uma hipótese distinta sobre a formação de novas conexões na rede. Os métodos baseados em similaridade local, como *Adamic-Adar* e *Resource Allocation*, consideram que duas doenças têm maior probabilidade de se conectar quanto mais genes raros e exclusivos compartilham, atribuindo maior peso a vizinhos pouco conectados. O coeficiente de *Jaccard*, por sua vez, avalia a proporção de genes compartilhados em relação ao total de genes associados a ambas as doenças, sendo uma medida clássica de similaridade. Já o método de *Preferential Attachment* parte da premissa de que doenças com muitos genes associados (alto grau) tendem a formar ainda mais conexões, independentemente da especificidade biológica dessas relações. Ao aplicar esses métodos, buscamos entender se a estrutura da rede é guiada principalmente por similaridade biológica — ou seja, pela presença de genes compartilhados e específicos — ou por mecanismos mais gerais de conectividade, como a popularidade dos nós.

O experimento consistiu em remover aleatoriamente 10% das arestas do grafo e tentar recuperá-las utilizando cada um dos métodos, repetindo o processo por 5 rodadas com diferentes sementes aleatórias. O desempenho foi avaliado pelas métricas ROC-AUC e PR-AUC, que quantificam a capacidade dos métodos em distinguir corretamente as arestas reais das não existentes.


Os resultados médios obtidos estão apresentados na Tabela 3:

Tabela 3: Resultados médios dos métodos de predição de links (5 rodadas, 10% removido)


Método	ROC-AUC	PR-AUC
<i>Adamic-Adar</i>	0.9601	0.9603
<i>Resource Allocation</i>	0.9601	0.9603
<i>Jaccard</i>	0.9576	0.9559
<i>Preferential Attachment</i>	0.7240	0.7606

Observa-se que os métodos baseados em similaridade local (*Adamic-Adar*, *Resource Allocation* e *Jaccard*) apresentaram desempenho excepcional, com valores de ROC-AUC e PR-AUC próximos de 1, indicando alta capacidade de recuperar as conexões removidas. Por outro lado, o método de *Preferential Attachment* teve desempenho significativamente inferior, sugerindo que, na rede de doenças analisada, a formação de novas conexões é melhor explicada por mecanismos de similaridade do que por simples preferência por nós de alto grau.


As curvas ROC e *Precision-Recall* para cada método, apresentadas nas Figuras 11 e 12, reforçam esses achados, mostrando separação clara entre positivos e negativos para os métodos baseados em similaridade.




(a) *Adamic-Adar*



(b) *Resource Allocation*




(c) *Jaccard*




(d) *Preferential Attachment*


Figura 11: Curvas ROC para os métodos de predição de links.




(a) *Adamic-Adar*



(b) *Resource Allocation*



(c) *Jaccard*



(d) *Preferential Attachment*

Figura 12: Curvas *Precision-Recall* para os métodos de predição de links.

Esses resultados indicam que a estrutura da rede de doenças é altamente informativa para a predição

de novas associações genéticas, e que abordagens baseadas em similaridade local são particularmente eficazes nesse contexto.

3.9 Triadic Closure

A análise de *triadic closure* quantifica a presença de grupos fechados de três doenças (triângulos) na rede, refletindo a tendência de que, se duas doenças compartilham similaridade genética com uma terceira, também tendam a se relacionar entre si. No grafo analisado, foram identificados 31716 triângulos, com uma transitividade global (razão de fechamento triádico) de 0.0968. O valor de 0.0968 indica que a rede possui uma quantidade significativa de agrupamentos fechados, reforçando a existência de comunidades e modularidade, mesmo em uma estrutura dominada por *hubs*. Isso é típico de redes biológicas e sugere organização não aleatória e presença de grupos de doenças fortemente interligadas.

Para efeito de comparação, uma rede aleatória de mesmo porte apresentou apenas 26 triângulos e transitividade de 0.0004, evidenciando que a formação de triângulos na rede real é muito mais frequente do que seria esperado ao acaso. Isso reforça a existência de agrupamentos e módulos funcionais na rede de doenças.

A Tabela 4 apresenta as dez doenças que participam do maior número de triângulos. Observa-se que as doenças centrais, como “*Diabetes Mellitus, Experimental*” e “*Disease Models, Animal*”, estão envolvidas em centenas de triângulos, atuando como vértices-chave na integração de múltiplos grupos.

Tabela 4: Top 10 nós que participam de mais triângulos na rede

Nó	Nº de triângulos
<i>Diabetes Mellitus, Experimental</i>	970
<i>Disease Models, Animal</i>	695
<i>Carcinoma</i>	641
<i>Prostatic Neoplasms</i>	522
<i>Craniofacial Abnormalities</i>	491
<i>Hypertension</i>	447
<i>Colorectal Neoplasms</i>	346
<i>Child Development Disorders, Pervasive</i>	323
<i>Body Weight</i>	315
<i>Fibrosis</i>	311

Esses resultados indicam que a rede de doenças é altamente propensa à formação de grupos coesos, com *hubs* centrais participando de múltiplos triângulos e promovendo a integração entre diferentes módulos. A transitividade significativamente maior do que a de uma rede aleatória reforça a presença de modularidade e organização não aleatória na rede biológica analisada.

4 Visualização da rede

Para explorar a estrutura da rede de doenças, foram geradas diferentes visualizações que destacam tanto a organização global quanto padrões locais de agrupamento. A Figura 13 apresenta uma visualização reduzida da rede, onde cada nó representa uma comunidade detectada pelo algoritmo de modularidade e o tamanho do nó é proporcional ao número de doenças em cada grupo. As arestas refletem a intensidade das conexões entre comunidades, evidenciando que a maior parte das interações ocorre entre poucos grupos principais, enquanto diversas comunidades menores mantêm ligações pe-

riféricas. Essa representação facilita a identificação de módulos densos e da arquitetura hierárquica da rede.




Figura 13: Rede com supernós representando cada uma das 46 comunidades

As Figuras 14a e 14b mostram um subgrafo amostrado da rede original, com 15% das arestas selecionadas aleatoriamente. Os nós estão coloridos de acordo com seu coeficiente de clusterização, formando um *heatmap* que destaca regiões altamente coesas (em amarelo) e áreas mais dispersas (em azul escuro). Observa-se que a maioria dos nós apresenta baixos valores de clusterização, indicando uma estrutura predominantemente dispersa, com poucos agrupamentos densos. Os vértices com valores mais altos (em amarelo) concentram-se em pequenas regiões, geralmente associadas a comunidades internas. Essa visualização evidencia a modularidade da rede e sugere que as conexões entre módulos ocorrem por meio de poucos nós intermediários.




Figura 14: Subgrafo com 15% das arestas originais randomizadas por 2 *layouts* diferentes

Por fim, a Figura 15 exibe o *heatmap* da matriz de adjacência entre comunidades, onde a intensidade da cor indica o peso das conexões entre diferentes grupos. Nota-se que as interações mais fortes estão concentradas entre algumas comunidades específicas, enquanto a maioria das ligações é esparsa. Esse padrão sugere que a rede é composta por módulos bem definidos, com poucos pontos de integração entre eles, característica típica de sistemas biológicos complexos.




Figura 15: Heatmap da matriz de adjacências entre comunidades.

Essas visualizações, em conjunto, evidenciam a natureza altamente modular da rede de doenças, a existência de comunidades densas e a importância de poucos nós e grupos para a integração global da rede.

5 Conclusão

O projeto permitiu caracterizar de forma abrangente a estrutura da rede de similaridade genética entre doenças obtida a partir do DisGeNET, revelando uma organização altamente modular e não aleatória. A filtragem pelo algoritmo TMFG se mostrou eficaz em preservar as conexões mais relevantes, reduzindo a complexidade da rede e destacando sua natureza livre de escala. As análises de centralidade apontaram o “*Diabetes Mellitus, Experimental*” como o principal *hub*, conectando diversas comunidades e desempenhando papel central na integração global da rede. A clusterização e a análise de *triadic closure* confirmaram a presença de agrupamentos densos de doenças geneticamente relacionadas, interligados por poucos nós de baixa clusterização. Os métodos de *link prediction* baseados em similaridade mostraram alto desempenho, indicando que a topologia da rede reflete fortemente a proximidade biológica entre doenças. Por fim, as visualizações corroboraram a modularidade e a hierarquia estrutural do sistema, evidenciando que a rede de doenças analisada segue padrões típicos de sistemas biológicos complexos, nos quais poucos elementos centrais sustentam a coesão e a conectividade global.

Referências

- [1] Extracting disease–gene associations from DisGeNET, <https://github.com/dhimmel/disgenet>
- [2] M. Tumminello, T. Aste, T. Di Matteo, and R. N. Mantegna, A tool for filtering information in complex systems <https://www.pnas.org/doi/10.1073/pnas.0500298102>
- [3] Kuratowski’s theorem, https://en.wikipedia.org/wiki/Kuratowski%27s_theorem
- [4] Guido Previde Massara, T. Di Matteo, Tomaso Aste, Network Filtering for Big Data: Triangulated Maximally Filtered Graph, <https://academic.oup.com/comnet/article/5/2/161/2555365>